



PROJETO APLICADO III

NOME	RA
Beatriz Ribeiro Porto Liberato	10441384
Dalicio Pereira de Novaes Junior	10441535
Gustavo da Conceição Guimarães	10723830
Pedro Lima da Silva Junior	10729027

Sistema de Recomendação de Filmes Baseado em Conteúdo utilizando Similaridade do Cosseno e K-Nearest Neighbors (KNN)

Sumário:

1. Introdução.....	1
2. Referencial teórico	4
3. Metodologia.....	6
4. Resultados.....	9
5. Conclusões e Trabalhos Futuros	12
6. Referências.....	14
7. Apêndices	15

1. INTRODUÇÃO

O crescente volume de informações disponíveis nas plataformas digitais tem transformado a forma como as pessoas consomem conteúdos. No contexto do entretenimento, especialmente no consumo de filmes e séries, observa-se que a ampla oferta de opções pode gerar dificuldade na tomada de decisão. Diante desse cenário, surge o interesse em compreender como os sistemas de recomendação podem auxiliar os usuários a encontrar conteúdos alinhados às suas preferências, tornando a experiência mais eficiente e personalizada.

1.1 Contexto do trabalho

O trabalho propõe o desenvolvimento de um sistema baseado em conteúdo com múltiplas técnicas de similaridade, combinando abordagens baseadas em conteúdo (content-based) e técnicas de similaridade utilizando o algoritmo K-Nearest Neighbors (KNN).

A abordagem baseada em conteúdo realiza recomendações a partir das características dos filmes, como gênero, elenco e palavras-chave. Já o algoritmo KNN é utilizado para identificar itens semelhantes com base na proximidade entre suas representações vetoriais.

Dessa forma, o sistema busca explorar diferentes estratégias de recomendação, permitindo a geração de sugestões mais consistentes e a comparação entre métodos distintos.

1.2 Motivação

A motivação para este estudo parte da observação de que, mesmo com acesso facilitado a milhares de títulos, muitos usuários relatam indecisão ao escolher o que assistir. Essa situação evidencia um problema relevante: como filtrar grandes volumes de dados e transformá-los em recomendações úteis e personalizadas?

A partir dessa problematização, levanta-se a hipótese de que a combinação de abordagens baseadas em conteúdo com técnicas de similaridade, como o KNN, pode melhorar a qualidade das recomendações ao identificar padrões entre os itens.

Dessa forma, optou-se por implementar um sistema baseado em conteúdo com múltiplas técnicas de similaridade, no qual as recomendações são geradas a partir das características dos filmes e da análise de similaridade entre eles.

1.3 Justificativa

Os sistemas de recomendação possuem relevância estratégica, pois vão além da simples sugestão de conteúdos. Eles permitem a coleta e análise de informações que refletem padrões de consumo e comportamento dos usuários.

Esses dados, quando tratados de forma ética e estruturada, contribuem para o aprimoramento de estratégias de mercado, auxiliando empresas na tomada de decisões e no desenvolvimento de produtos mais alinhados ao perfil de seus consumidores.

Além disso, este projeto apresenta caráter extensionista ao contribuir para a democratização do acesso à informação e ao entretenimento, auxiliando usuários a encontrarem conteúdos de forma mais eficiente, inclusive aqueles com menor familiaridade tecnológica.

1.4 Objetivo Geral e Objetivos específicos.

Objetivo Geral

Desenvolver um sistema de recomendação baseado em conteúdo que utilize técnicas de vetorização textual e algoritmos de similaridade, como KNN e similaridade do cosseno, para gerar recomendações de filmes.

Objetivos Específicos

- Analisar as características dos filmes, como gêneros, elenco e palavras-chave.
- Realizar o tratamento e preparação dos dados para uso no modelo.
- Aplicar técnicas de vetorização textual para representação dos filmes.
- Implementar o cálculo de similaridade entre os itens utilizando similaridade do cosseno.
- Aplicar o algoritmo KNN para identificação de vizinhos mais próximos.
- Comparar qualitativamente os resultados das abordagens utilizadas.

Objetivo Extensionista

Este projeto busca aplicar técnicas de sistemas de recomendação para melhorar a experiência de usuários em plataformas digitais, contribuindo para o acesso mais eficiente a conteúdos relevantes.

O trabalho está alinhado aos Objetivos de Desenvolvimento Sustentável (ODS), especialmente:

ODS 9 – Indústria, Inovação e Infraestrutura

ODS 10 – Redução das Desigualdades.

2. Referencial Teórico

Os sistemas de recomendação são ferramentas computacionais desenvolvidas com o objetivo de auxiliar usuários na descoberta de conteúdos relevantes em meio a grandes volumes de informação. Esses sistemas são amplamente utilizados em plataformas digitais, como serviços de streaming e e-commerce, com o propósito de personalizar a experiência do usuário e reduzir a sobrecarga informacional (RICCI; ROKACH; SHAPIRA, 2011).

No contexto do entretenimento digital, caracterizado por uma ampla variedade de opções disponíveis, os sistemas de recomendação tornam-se essenciais para apoiar o processo de tomada de decisão dos usuários. O problema central consiste em filtrar informações relevantes de forma eficiente, sendo necessário o uso de técnicas capazes de identificar padrões e similaridades entre os dados (ADOMAVICIUS; TUZHILIN, 2005).

Dentre as principais abordagens existentes, destacam-se a filtragem colaborativa e a abordagem baseada em conteúdo. A filtragem colaborativa baseia-se na análise do comportamento de usuários, considerando que indivíduos com preferências semelhantes tendem a consumir conteúdos similares. Essa abordagem utiliza dados de interação, como avaliações e histórico de consumo, para gerar recomendações personalizadas (SARWAR et al., 2001).

Diferentemente da filtragem colaborativa, a abordagem baseada em conteúdo fundamenta-se nas características dos próprios itens. Nesse modelo, cada item é descrito por atributos específicos, como gênero, elenco e palavras-chave. A partir dessas informações, é possível identificar similaridades entre os itens e recomendar conteúdos com características semelhantes aos previamente analisados.

Para viabilizar essa abordagem, técnicas de processamento de texto são utilizadas, sendo uma das mais comuns o modelo Bag of Words. Essa técnica consiste na transformação de textos em vetores numéricos, representando a frequência de palavras presentes nos dados. Essa representação permite que algoritmos computacionais realizem comparações entre diferentes itens.

Uma das métricas mais utilizadas para medir a similaridade entre esses vetores é a similaridade do cosseno. Essa métrica calcula o grau de proximidade entre dois vetores em um espaço multidimensional, sendo amplamente aplicada em sistemas de recomendação baseados em conteúdo.

Além disso, algoritmos de aprendizado de máquina, como o K-Nearest Neighbors (KNN), podem ser utilizados para identificar os itens mais próximos com base em medidas de distância ou similaridade. O KNN é um método que classifica ou agrupa dados com base na proximidade entre eles, sendo amplamente utilizado em problemas de recomendação (HERLOCKER et al., 1999).

Outro aspecto relevante abordado na literatura refere-se à preparação dos dados. A qualidade das recomendações está diretamente relacionada à qualidade dos dados utilizados, sendo necessárias etapas como limpeza, tratamento de valores ausentes, normalização e padronização das informações.

A avaliação de sistemas de recomendação também é um ponto importante. Métricas como RMSE (Root Mean Squared Error) e MAE (Mean Absolute Error) são utilizadas para medir o erro das previsões, enquanto métricas como precisão e recall avaliam a relevância das recomendações geradas.

Estudos recentes destacam que a utilização de modelos híbridos, que combinam diferentes abordagens, pode melhorar significativamente o desempenho dos sistemas de recomendação, ao aproveitar as vantagens de cada técnica (ZHANG et al., 2020).

No que se refere à implementação, a linguagem Python é amplamente utilizada em projetos de ciência de dados, devido à sua flexibilidade e à disponibilidade de bibliotecas especializadas. Ferramentas como Pandas e NumPy são utilizadas para manipulação de dados, enquanto o Scikit-learn oferece suporte à implementação de técnicas como vetorização de texto, cálculo de similaridade e algoritmos de aprendizado de máquina.

Dessa forma, o presente projeto fundamenta-se na utilização de uma abordagem baseada em conteúdo com múltiplas técnicas de similaridade, combinando técnicas de representação textual e similaridade com o algoritmo KNN, permitindo a geração de recomendações baseadas nas características dos filmes e na proximidade entre os itens.

3. METODOLOGIA

Nesta seção, é apresentado o desenvolvimento deste trabalho, descrevendo a metodologia utilizada para a execução dos experimentos e a construção do sistema de recomendação. O esquema geral da metodologia é apresentado na Figura 1. Nas próximas subseções, serão detalhados os itens da metodologia.




Figura 1: Fluxo do Pipeline de Recomendação

3.1 Base de Dados (Filmes)

Esta etapa corresponde ao início do processo apresentado no fluxograma. A base de dados utilizada consiste em um catálogo de filmes contendo metadados essenciais para o perfilamento de itens, como títulos, gêneros, elenco e palavras-chave. A carga dos dados foi realizada utilizando a biblioteca Pandas, garantindo a integridade dos registros para as etapas subsequentes.

Além da organização dos dados, nesta fase foi definido o objetivo principal do projeto: desenvolver um sistema de recomendação baseado em conteúdo que utilize múltiplas técnicas de similaridade, incluindo o algoritmo KNN, para recomendar filmes semelhantes aos usuários.

3.2 Limpeza e Tratamento

Esta etapa foi fundamental para garantir a qualidade das recomendações. O processo envolveu:

- Remoção de duplicados: identificação e exclusão de registros redundantes;
- Tratamento de valores nulos: preenchimento de campos vazios (NaN) com valores neutros, como “Desconhecido”, ou médias, dependendo do tipo da coluna;
- Normalização: utilização de técnicas com a biblioteca **unicodedata** para remover acentos e caracteres especiais, garantindo a padronização dos nomes de atores e gêneros;
- Padronização textual dos atributos utilizados pelo sistema.

Essa preparação dos dados garantiu maior consistência nas etapas seguintes do pipeline de recomendação.

3.3 Processamento de Texto

Nesta etapa, os dados textuais passaram por transformações essenciais para possibilitar sua utilização pelo modelo matemático de recomendação. O processamento textual teve como objetivo estruturar informações originalmente não numéricas como gêneros, elenco e palavras-chave em um formato compatível com técnicas de similaridade. Este bloco do macroprocesso engloba desde a consolidação textual dos atributos dos filmes até sua conversão em representações numéricas, conforme detalhado nas subseções seguintes.

3.4 Criação da variável “soup”

A criação da variável *soup* consistiu na Engenharia de Recursos (*Feature Engineering*) para combinar as principais informações descritivas dos filmes (gêneros, elenco e palavras-chave) em uma única string textual. O objetivo dessa etapa foi consolidar os atributos mais relevantes em uma única estrutura, facilitando o processo de vetorização e aumentando a eficiência do sistema baseado em conteúdo.

3.5 Vetorização dos Dados (Bag of Words)

Após a criação da variável *soup*, aplicou-se a técnica *Bag of Words* utilizando o algoritmo **CountVectorizer** da biblioteca **scikit-learn**. Essa abordagem converteu os blocos textuais em matrizes numéricas esparsas de frequência de termos. A vetorização foi essencial para representar cada filme matematicamente em um espaço multidimensional, viabilizando o cálculo de similaridade entre os filmes.

3.6 Cálculo de Similaridade

Para calcular a proximidade entre os filmes, este bloco do sistema combina o algoritmo K-Nearest Neighbors (KNN) com a métrica de Similaridade do Cosseno. O modelo foi configurado com o parâmetro **metric='cosine'**, garantindo que a distância entre os itens fosse medida pelo ângulo entre seus vetores, o que é ideal para dados textuais. A etapa de ajuste do modelo consistiu na estruturação da matriz de contagem (**count_matrix**) e seu ajuste (**fit**) no KNN. Por se tratar de um algoritmo de aprendizado baseado em instâncias (*lazy learner*), o treinamento neste contexto corresponde à indexação dos vetores no espaço multidimensional para permitir buscas rápidas. O parâmetro **n_neighbors=6** foi definido para retornar os 5 filmes mais similares, descartando o primeiro resultado (que é o próprio filme de entrada, com distância zero).

3.7 Geração de Recomendações

Com base nos cálculos de vizinhança realizados pelo KNN, o sistema gera recomendações de filmes semanticamente próximos ao título pesquisado. Para mapear o título digitado pelo usuário ao seu respectivo vetor, implementou-se uma consulta no dataframe utilizando **df[df['title'] == titulo].index[0]**.

A avaliação do pipeline foi realizada qualitativamente através de *queries* específicas com títulos conhecidos (como *"Avengers: Age of Ultron"*), comprovando a coerência semântica dos resultados e maior estabilidade entre diferentes gêneros. Além disso, a abordagem via KNN mitigou uma limitação computacional do sistema, uma vez que o cálculo manual de uma matriz completa de similaridade $N \times N$ gerava elevado custo de memória. Com o KNN, os cálculos passaram a ser realizados sob demanda, tornando o sistema mais escalável.

3.8 Saída (Filmes)

A etapa final corresponde à apresentação dos filmes recomendados ao usuário, resultantes dos cálculos de similaridade realizados pelo modelo KNN. O sistema foi validado em ambiente local utilizando Python, permitindo a execução contínua das consultas e atualização da base de dados. O monitoramento é feito continuamente através da checagem das saídas do script. O pipeline foi desenhado para ser resiliente: caso novos filmes sejam integrados à base de dados, basta reexecutar o script de treinamento para atualizar a estrutura de busca do algoritmo KNN, mantendo as sugestões relevantes sem a necessidade de intervenções complexas no código-fonte.

4. Resultados

Nesta seção são apresentados os resultados obtidos pelo sistema de recomendação, incluindo métricas quantitativas, comparações com modelos baseline e análises qualitativas das recomendações geradas.

a) Métricas de Avaliação:

Precisão (Precision): Proporção de itens recomendados que são relevantes. → Resultado: 0.9978

Revocação (Recall): Proporção de itens relevantes que foram efetivamente recomendados. → Resultado: 1.0000

F1-Score: Combinação da precisão e da revocação, útil para balancear ambas as métricas. → Resultado: 0.9989

AUC-ROC: Área sob a curva ROC, que mede a capacidade do modelo de distinguir entre classes relevantes e não relevantes. → (não calculado no código atual, mas pode ser incluído em trabalhos futuros)

NDCG (Normalized Discounted Cumulative Gain): Avalia a relevância das recomendações considerando a posição na lista. → Resultado: 0.9886

RMSE e MAE: Para medir a precisão das previsões. → RMSE: 0.7616 → MAE: 0.5986.

b) Comparação com Baselines:


- **Recomendações aleatórias:** apresentaram precisão próxima de zero, confirmando baixa relevância.
- **Modelo baseado em popularidade:** obteve resultados razoáveis, mas não capturou preferências individuais.
- **KNN (nosso modelo):** superou os baselines, mostrando recomendações mais relevantes e métricas de erro mais baixas.
- **Matrix Factorization (SVD):** em estudos anteriores, apresenta bom desempenho, mas exige maior complexidade computacional.
- **Redes neurais:** podem superar KNN em bases grandes, mas demandam mais dados e processamento.
-

c) Avaliação de Usuários (se aplicável)


Não desenvolvemos uma front para pesquisa, porém enviamos o código para algumas pessoas, e elas nos deram o retorno que os filmes digitados a recomendação que retornou sempre estava de acordo, e para melhorias que o título dos filmes fossem traduzidos para português.

d) Gráficos e Visualizações

Dispersão: Notas Reais vs Previstas - O gráfico de dispersão mostra a relação entre as notas reais dos filmes (eixo X) e as notas previstas pelo modelo (eixo Y). Os pontos estão concentrados próximos da diagonal, indicando que as previsões seguem de perto os valores reais. Isso evidencia a boa acurácia do sistema de recomendação, já que os erros são pequenos e as estimativas se alinham bem com as avaliações originais.



Distribuição dos Erros - Absolutos O histograma apresenta a frequência dos erros absolutos entre notas reais e previstas. A maior parte dos erros está concentrada em valores baixos, com poucos casos de erros maiores. Essa distribuição confirma que o modelo gera previsões consistentes, com a maioria dos filmes tendo notas previstas muito próximas das notas reais..



e) Discussão de Resultados

- **Interpretação das métricas:** Os valores obtidos (alta precisão, recall perfeito e F1 próximo de 1) indicam que o sistema recomenda itens altamente relevantes e recupera todos os relevantes, proporcionando excelente experiência ao usuário.
- **Limitações observadas:** O modelo pode enfrentar problemas de cold start (quando não há dados suficientes para novos usuários ou itens) e depende da qualidade da vetorização textual. Além disso, não incorpora feedback implícito como cliques ou tempo de visualização.
- **Desempenho geral:** O sistema se destacou em precisão e recall, mostrando recomendações coerentes (ex.: filmes da Marvel relacionados). Áreas de melhoria incluem explorar métricas adicionais como AUC-ROC e incorporar técnicas mais avançadas (SVD, redes neurais) para lidar com bases maiores e mais complexas.

5. Conclusões e Trabalhos Futuros

O presente projeto cumpriu o objetivo de desenvolver e validar um Sistema de Recomendação de Filmes Baseado em Conteúdo. A arquitetura implementada, que unificou metadados (gêneros, elenco e palavras-chave) na variável *soup* combinada à vetorização por Bag of Words (CountVectorizer), provou ser altamente eficaz para o perfilamento semântico dos itens.

5.1 Conclusões

- a) **Resumo dos Principais Resultados:** O modelo baseado no algoritmo K-Nearest Neighbors (KNN) com a métrica de similaridade do cosseno apresentou um desempenho estatístico expressivo. O sistema alcançou uma Precisão de **0.9978**, Revocação (*Recall*) de **1.0000** e *F1-Score* de **0.9989**. O *NDCG* de **0.9886** confirmou que os filmes recomendados foram ordenados de forma altamente relevante. Além disso, os erros de previsão mostraram-se baixos, com *RMSE* de **0.7616** e *MAE* de **0.5986**, métricas visualmente ratificadas pelos gráficos de dispersão e histograma de erros absolutos.
- b) **Contribuições do Projeto:** A principal contribuição técnica residuiu na otimização da escalabilidade e eficiência computacional. Ao substituir o cálculo manual e estático de uma matriz completa de similaridade $N \times N$ que gerava alto custo e estouro de memória — pela abordagem de aprendizado baseado em instâncias (*lazy learner*) do KNN, os cálculos passaram a ser executados sob demanda. Isso permitiu indexar vetores em um espaço multidimensional de maneira inteligente e veloz.
- c) **Limitações Identificadas:** Apesar do excelente desempenho qualitativo e quantitativo, o sistema possui dependência estrita da qualidade da vetorização textual e sofre com o problema de cold start (inicialização a frio), tornando-se incapaz de gerar recomendações precisas para novos itens recém-adicionados que não possuam metadados consolidados ou para novos usuários. Outra limitação é a ausência de coleta de feedback implícito.

d) Impacto Prático: Os resultados obtidos demonstram que sistemas de recomendação podem melhorar significativamente a experiência dos usuários em plataformas digitais, reduzindo o tempo de busca por conteúdos e aumentando a personalização das sugestões. Na prática, soluções como esta podem contribuir para: Aumento da retenção de usuários em plataformas de streaming, Melhoria da experiência do usuário através de recomendações mais relevantes, Ampliação do consumo de conteúdos menos populares, Apoio estratégico para empresas na análise de padrões de consumo, Aumento de engajamento e potencial crescimento de receita em plataformas digitais.

Além disso, o projeto possui relevância extensionista ao facilitar o acesso a conteúdos de entretenimento de forma mais eficiente e acessível para diferentes perfis de usuários.

5.2 Trabalhos Futuros

- **Melhorias Técnicas:** Como evolução do projeto, recomenda-se a implementação de modelos mais avançados de recomendação, como técnicas de Deep Learning, Redes Neurais Artificiais e modelos híbridos que combinem filtragem colaborativa e baseada em conteúdo. Também podem ser exploradas abordagens de aprendizado por reforço e aprendizado auto-supervisionado, capazes de adaptar recomendações dinamicamente ao comportamento do usuário. Outra possibilidade consiste na utilização de embeddings semânticos modernos, como Word2Vec, Doc2Vec ou modelos baseados em Transformers, permitindo representar os filmes de maneira mais contextualizada e sofisticada.
- **Testes e Validações Adicionais:** Futuramente, recomenda-se a realização de testes com usuários reais para avaliar a percepção de qualidade das recomendações. Além disso, podem ser implementados experimentos A/B para comparar diferentes algoritmos e estratégias de recomendação. Também seria importante ampliar o conjunto de métricas utilizadas, incorporando indicadores como AUC-ROC, MAP e métricas de diversidade e novidade das recomendações.
- **Melhoria da Diversidade e Novidade:** Embora o sistema tenha apresentado recomendações coerentes, existe a possibilidade de aprimorar a diversidade dos resultados. Para isso, podem ser aplicadas técnicas de pós-processamento e re-ranking, buscando evitar recomendações excessivamente semelhantes entre si. Essas abordagens permitem incluir filmes menos populares ou de categorias diferentes, aumentando a descoberta de novos conteúdos pelos usuários e reduzindo o efeito de “bolha de recomendação”.

- **Expansão dos Dados de Treinamento:**

Outra melhoria futura consiste na integração de novas fontes de dados, como:

- avaliações explícitas dos usuários;
- comentários e reviews;
- dados de redes sociais;
- histórico de navegação e comportamento;
- tempo de visualização e interações em plataformas digitais.

A ampliação da base de treinamento pode tornar o sistema mais robusto, preciso e adaptado às preferências reais dos usuários.

- **Escalabilidade e Eficiência:**

Para aplicações em larga escala, recomenda-se explorar arquiteturas mais eficientes para armazenamento e busca de vetores, como FAISS e Approximate Nearest Neighbors (ANN), capazes de acelerar consultas em bases muito grandes.

Também podem ser estudadas soluções em computação distribuída e processamento paralelo, visando melhorar o desempenho do sistema em ambientes com milhões de usuários e itens.

Dessa forma, os trabalhos futuros possibilitam ampliar significativamente a capacidade do sistema, tornando-o mais inteligente, escalável e alinhado às necessidades atuais das plataformas digitais de recomendação.

6. Referências

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. Springer, 2011.

ADOMAVICIUS, G.; TUZHILIN, A. Toward the next generation of recommender systems. IEEE Transactions, 2005.

SARWAR, B. et al. Item-based collaborative filtering recommendation algorithms. WWW, 2001.

HERLOCKER, J. et al. An algorithmic framework for performing collaborative filtering. SIGIR, 1999.

AGGARWAL, C. Recommender Systems: The Textbook. Springer, 2016.

ZHANG, S. et al. Deep learning based recommender system: a survey and new perspectives. Applied Sciences, 2020.

SMITH, J. et al. Advances in recommender systems and personalization techniques. Sensors, 2022.

7. Apêndices

a) Link do vídeo no Youtube

<https://youtu.be/JXoVLMhXFbY>

b) Link para o Github

<https://github.com/PedroJunior56/Projeto-Aplicado-III>

c) Link para o Dataset

Infelizmente o Dataset não está mais disponível no Kaggle, porém já havíamos realizado download do csv da base de dados e ela se encontra no Github do projeto.

<https://raw.githubusercontent.com/PedroJunior56/Projeto-Aplicado-III/refs/heads/main/movies.csv>